Elementarni postupak diferencijalnog praćenja
Tehnička dokumentacija
Verzija 1.1

Studentski tim: Kristijan Biščanić
Matej Djerdji
Ivan Fabijanić
Josip Milić
Dario Pažin

Nastavnik: Prof. dr.sc. Siniša Šegvić

Sadržaj

1. Uvod

Ljudski vid je osjetilo pomoću kojeg čovjek ostvaruje percepciju objekata ili pojava iz njegove okoline. Područje računalnog vida je područje umjetne inteligencije koje istražuje navedenu percepciju u svrhu nalaženja načina za što vjernije računalno oponašanje ljudskog vida i rješenja koja služe kao pomoć čovjeku u razumijevanju njegove (ne)posredne okoline. Umjesto korištenja ljudskog oka i mozga uz biokemijske procese za ostvarenje vida, računalo koristi vanjsku jedinicu sa sposobnošću pretvorbe svjetlosnih signala u digitalni oblik i procesne jedinice koje složenim matematičkim operacijama obrađuju dobivene podatke. Od mnogih problemskih zadataka koji su iz domene područja računalnog vida najčešći su prepoznavanje objekata, analiza pokreta, rekonstrukcija i restauracija slika. Neki od primjera tih zadataka: prepoznavanje lica, praćenje značajki u video snimci, stvaranje 3D modela temeljem slika i video snimke, čišćenje šuma na slikama kao pomoć u dijagnostici i mnogi drugi. Rješenja većine tih problema postoje već desetljećima, ali tek snažnim razvojem računala (algoritmi rješenja, ukoliko se želi prihvatljivo brzo dobiti koristan rezultat, nerijetko zahtijevaju velike računalne performanse) u novije doba dolaze do izražaja upotrebom u mnogim granama ljudske djelatnosti (medicina, poljoprivreda, filmska umjetnost i mnoge druge). Daljnjim razvojem i povećavanjem računalnih performansi, rješenja tih problema (i ona koja će tek nastati) će se sigurno sve više implementirati u mnoge postojeće djelatnosti čineći ih efikasnijim i(li) kvalitetnijim. Poučeni računalnom poviješću možemo pretpostaviti i stvaranje djelatnosti koje su usko vezane uz područje računalnog vida, a danas su nam gotovo nezamislive.

Elementarni postupak diferencijalnog praćenja je problemski zadatak analize pokreta u kojem se traži praćenje određenih značajki u nizu slika. Kod diferencijalnog praćenja posmaknuta slika se aproksimira Taylorovim razvojem. U tom razvoju se javljaju parcijalne derivacije slike po koordinatama pomaka (odnosno gradijent slike) te zbog toga taj postupak nazivamo diferencijalnim. Prednost tog postupka je što se može dobiti zatvoreni oblik podpikselnog pomaka kao rješenje linearnog sustava jednadžbi. Nedostatak postupka je u spomenutom Taylorovom razvoju jer je taj razvoj samo aproksimacija. Potrebno je iterativno ponavljanje osnovnog postupka kako bi se došlo do rješenja.

Jedno od mogućih rješenja tog problema je Kanade-Lucas-Tomasi pratitelj značajki[1] (skraćeno KLT pratitelj) i njegov se algoritam koristi i obrađuje u ovom projektu.

Značajka je ime za istaknutu informaciju slike koja je relevantna daljnjim operacijama kojima se dolazi do konačnog rješenja. U slučaju ovog projekta, značajke su Harrisovi kutovi koji se nađu na određenim slikama u nizu slika. Koristi se obrada slike na način da se rubovi istaknu uz pomoć Sobelovog operatora i izglade pomoću Gaussovog filtara. KLT algoritam, pojednostavljeno opisan, čita podatke slike, obrađuje ih za lakše i brže čitanje, pronalazi značajke (Harrisove kutove), u sljedećim slikama

[1] Engleski naziv: *Kanade-Lucas-Tomasi feature tracker*

pronalazi nove položaje tih značajki i iterativno ih uspoređuje s prethodno nađenim položajima značajki. Prikazuje one značajke kojima je pronašao novi položaj, a ostale odbacuje. Proces ponavlja za svaki podniz niza slika sve dok ne završi s cijelim nizom slika. Rezultat tog postupka odnosno projekta je niz slika s označenim značajkama u kojem se može jasno vidjeti praćenje i gubljenje nađenih značajki.

Programsko ostvarenje projekta sastoji se od prototipa i završnog programa. Prototip, implementiran Pythonom (v2.7), skriptnim jezikom, ima funkciju prikaza Harrisovih kutova na pojedinoj obrađenoj slici. Njegovim izvođenjem se može vidjeti koliko na brzinu izvedbe utječe odabir pojedinog programskog jezika odnosno kako je izvedba u jeziku C++ mnogo brža od one u Python jeziku. Prototipom se, u ranoj fazi projekta, predvidjela zahtjevnost ostatka projekta i temeljem toga se obratila potpuna pozornost na izvedbu u jeziku C++. Završni program, implementiran C++-om, jezikom opće namjene, koristi algoritam KLT uz pomoć kojeg ostvaruje praćenje značajki u nizu slika. Prototip i završni program imaju vrlo jednostavno grafičko sučelje uz pomoć kojeg se prikazuje slika s nađenim značajkama u slučaju prototipa odnosno niz slika s nađenim značajkama (koje se prikazuje u stvarnom vremenu prilikom postupka) u slučaju završnog programa. Značajka se na (pojedinoj) slici označava sitnim crvenim rombom.

Ulaz prototipa je slikovna datoteka, a izlaz je kopija ulazne datoteke s označenim značajkama koja se može otvoriti neovisno o prototipu. Ulaz završnog programa može biti video datoteka ili niz pojedinih slikovnih datoteka. Izlaz završnog programa je kopija video datoteke ili niza pojedinih slikovnih datoteka s označenim značajkama koja se može pokrenuti neovisno o završnom programu.

U svrhu prevođenja i testiranja programskog koda za prototip se koristio standardni Python IDLE, a za završni program Microsoft Visual Studio 2010. Obje verzije programa su koristile biblioteku programskih funkcija OpenCV (v2.4.6) koja je omogućila čitanje i ispis slikovnih odnosno video datoteka. Treba napomenuti instalaciju biblioteke OpenCV kao nužnost kako bi se mogao prevesti programski kod i složenost instalacije te biblioteke u C++ okruženju, točnije Microsoft Visual Studio okruženju što je, objašnjeno u 8. poglavlju (Upute za korištenje) koje bi se trebalo pročitati prije vlastitog prevođenja i testiranja programskog koda.

U sljedećim poglavljima bit će detaljno prikazano sve navedeno: obrada slika (2. poglavlje), traženje značajki (Harrisovih kutova) na slici (3. poglavlje), općeniti algoritam KLT (4. poglavlje), programska implementacija navedenog algoritma (5. poglavlje), eksperimentalni rezultati (6. poglavlje), zaključak (7. poglavlje), upute za korištenje (8. poglavlje) i popisa literature (9. poglavlje).

2. Korištene metode obrade slike

Prije same uporabe KLT algoritma u postupku, korisno je sliku obraditi. U ovom projektu se koristi Gaussov filtar za zaglađivanje slike čime se smanjuje šum (nekorisna informacija) i Sobelov operator za isticanje rubova (gradijenta slike) što se koristi i u pronalasku Harrisovih kutova, značajki (značajnih informacija slika) koje se koriste u ovom projektu. Prije obrade, slika se prebacuje u crno-bijelu verziju slike čime se pojednostavljuje postupak obrade (umjesto tri RGB[2] vrijednosti koje se koriste za prikaz određene boje piksela u originalnoj verziji koristi se samo jedna vrijednost nijansi sive u obrađenoj verziji). Slika 1 prikazuje korake obrade na dva primjera.

***Slika 1** - Originalna slika (1) se prebacuje u crno-bijelu verziju (2), ističe Sobelovim operatorom (3) i zaglađuje Gaussovim filtrom (4).*

[2] **RGB** je akronim za aditivni model boja u kojem se određena boja piksela prikazuje kombinacijom nijansi crvene (**R**ed), zelene (**G**reen) i plave (**B**lue) boje. Vrijednosti nijansi mogu biti od 0 do 255.

2.1. Određivanje gradijenta uz pomoć Sobelovog operatora

Za pronalazak Harrisovih kutova na slici potrebno je izračunati gradijent slike. To je moguće napraviti primjenom Sobelovog operatora koji daje dobru aproksimaciju gradijenta slike. Sobelov operator sastoji se od dva kernela (kvadratne matrice) – jedan za izračun derivacije po x – smjeru i drugi za izračun derivacije po y – smjeru. Kombinacijom rezultata primjene pojedinih kernela na sliku za koju treba izračunati gradijent, moguće je izračunati gradijent prema:

$$G = \sqrt{{G_x}^2 + {G_y}^2}\,,\ \theta = \tan^{-1}\frac{G_y}{G_x} \qquad (1)$$

gdje je G amplituda gradijenta, θ kut gradijenta, a G_x i G_y su derivacije po x i y smjeru dobivene primjenom Sobelovih kernela. Često se zbog povećanja performansi uvodi aproksimacija za izračun amplitude:

$$G = |G_x| + |G_y|. \qquad (2)$$

Sobelovi kerneli definirani su prema (n1). Ovakav format kernela implicira smjer pozitivne x-osi „s lijeva na desno“, a y-osi „gore prema dolje“.

$$G_x = \begin{bmatrix} +1 & 0 & -1 \\ +2 & 0 & -1 \\ +1 & 0 & -1 \end{bmatrix}, \quad G_y = \begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \qquad (3)$$

Kerneli se primjenjuju tako da se svaki posebno konvoluira sa izvorišnom slikom, a pošto su i ovi kerneli separabilni, broj potrebnih operacija za računanje derivacije u jednom smjeru za svaki piksel smanjuje se sa k^2 na 2*k, gdje je k veličina kernela (u ovom slučaju k=3). Separirani kerneli prikazani su u (n2).

$$G_x = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \begin{bmatrix} +1 & 0 & -1 \end{bmatrix}, \quad G_y = \begin{bmatrix} +1 \\ 0 \\ -1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 \end{bmatrix} \qquad (4)$$

Slika 2 prikazuje isticanje rubova na jednom primjeru. Posebno su označeni uvećani dijelovi koji služe za bolju preglednost.

***Slika 2** – Primjer isticanja rubova. Crvenom bojom je označen uvećan dio iz originalne verzije (1), a plavom iz obrađene verzije (bez zaglađivanja) (2).*

2.2. Zaglađivanje rubova Gaussovim filtrom

Zbog nesavršenosti kamera i fotoaparata zapisane digitalne fotografije sadrže određenu količinu Gaussovog šuma. Gaussov šum je signal čije vrijednosti podliježu Gaussovoj (normalnoj razdiobi), te su neovisne o poziciji i intenzitetu piksela na koji se pribrajaju. Kako bi se u krajnjim rezultatima smanjio utjecaj šuma, koji ne nosi nikakvu korisnu informaciju, potrebno je sliku prije bilo kakve daljnje obrade zagladiti. Kod zaglađivanja slike koristi se Gaussov filtar, G(x, y):

$$G(x,y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \qquad (5)$$

U funkciji G(x, y) veličina σ naziva se standardna devijacija i u ovom slučaju određuje mjeru „glađenja“: korištenjem manje veličine σ moguće je da se neće ukloniti sav šum, dok je korištenjem prevelikog σ moguće ukloniti i detalje slike koji su ustvari korisni kod daljnje obrade.

Gaussov filtar primjenjuje se tako da se funkcija G(x, y) konvoluira sa zadanom slikom I(x, y). U ovom projektu se koriste diskretne slike i zato se koristi diskretan Gaussov filtar i ostvaruje se kernelom - kvadratnom matricom dimenzije 2k+1.

Vrijednosti kernela H su iznosi kontinuirane funkcije G(x, y) na određenim koordinatama:

$$H(i,j) = \frac{1}{2\pi\sigma^2}\exp\left(-\frac{(i-k-1)^2+(j-k-1)^2}{2\sigma^2}\right),\ i,j\ \in(-k,k). \qquad (6)$$

Gaussov filtar moguće je rastaviti na x i y komponentu, te primijeniti svaku komponentu zasebno. Time se broj operacija potrebnih za računanje vrijednosti svakog piksela smanjuje sa k^2 na 2k. Potrebno je kernel H rastaviti na jedan vektor-redak h, koji pomnožen sa istim takvim, ali transponiranim retkom h^T daje polazni kernel H. Vrijednosti vektora h dimenzije k računaju se pomoću jednodimenzionalne Gaussove funkcije:

$$h(i) = \frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(i-k-1)^2}{2\sigma^2}\right),\ i\in(-k,k). \qquad (7)$$

Pritom se mora voditi računa o tome da veličina k (koja predstavlja veličinu kernela u pikselima) bude neparan broj, dakle oblika k = 2n + 1 i on se određuje pomoću sljedeće formule:

$$k = 2 * \lfloor 3\sigma \rceil + 1, \qquad \sigma \in R \qquad (8)$$

Time je osigurano da k bude neparan. Veličina 3σ koristi se kako bi kernel obuhvatio relevantan interval Gaussovog zvona koje je inače definirano nad cijelim skupom R^2. Dakle, Gaussov filtar je sasvim određen parametrom σ. Vrijednost pojedinog piksela $I'(x_1, y_1)$ u izglađenoj slici računa se, pomoću vektora h(i) duljine 2n + 1 na sljedeći način:

$$I'(x_1,y_1) = \sum_{i=-n}^{n} I(x_1+i,y_1) * h(i) + \sum_{i=-n}^{n} I(x_1,y_1+i) * h(i) \qquad (9)$$

Rezultat glađenja u pojedinom pikselu je linearna kombinacija vrijednosti „ne-izglađenog“ piksela i njegovih 2k susjednih piksela.
Slika 3 prikazuje zaglađivanje prethodno istaknutih rubova.

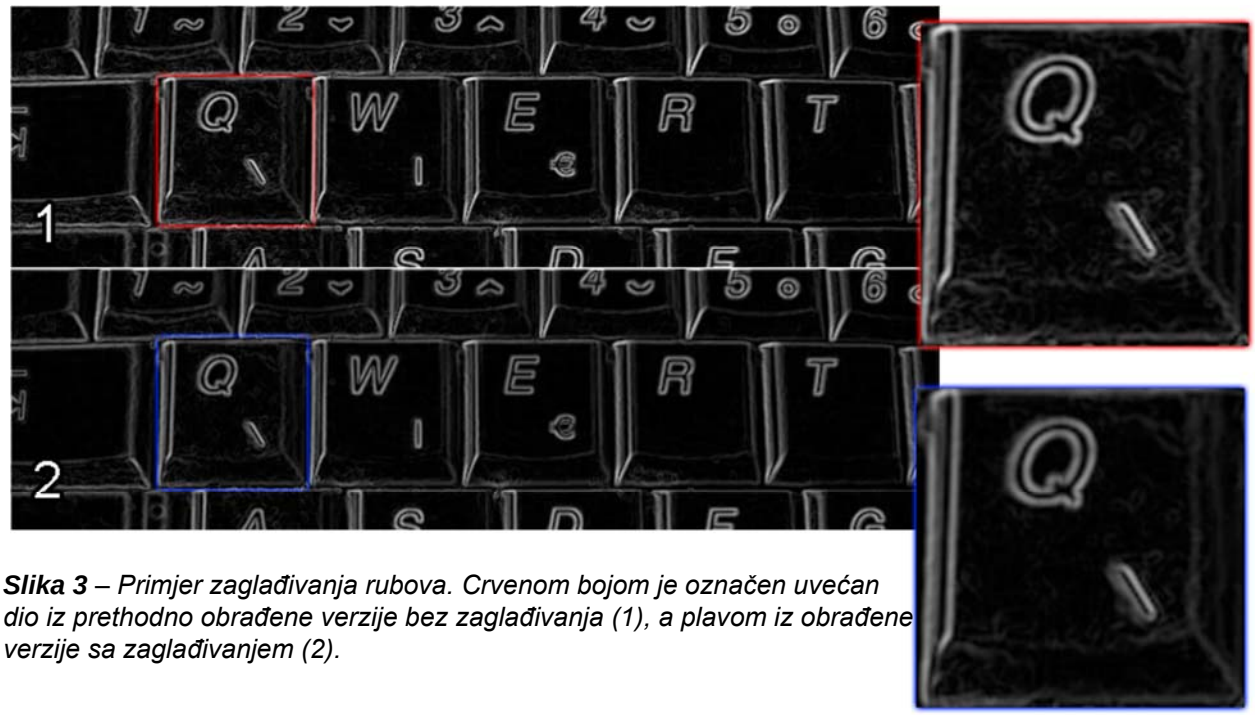

Slika 3 *– Primjer zaglađivanja rubova. Crvenom bojom je označen uvećan dio iz prethodno obrađene verzije bez zaglađivanja (1), a plavom iz obrađene verzije sa zaglađivanjem (2).*

2.3. Bilinearna interpolacija piksela

U matematici interpolacija predstavlja metodu izračunavanja novih vrijednosti funkcije iz diskretnog skupa zadanih vrijednosti kojeg dobivamo najčešće uzrokovanjem ili eksperimentalno. Interpolacija spada u temeljne metode digitalne obrade slike i služi za bolje praćenje zadanih vrijednosti. Linearna interpolacija definirana je nad dvije točke u jednodimenzionalnom prostoru.

$$y = y_a + (y_b - y_a)\frac{x - x_a}{x_b - x_a}\text{, u točki (x, y)} \qquad (10)$$

U dvodimenzionalnom prostoru takva interpolacija naziva se bilinearna interpolacija i predstavlja proširenje već spomenute linearne intrepolacije. Rezultat bilinearne interpolacije u cjelini nije linearnog oblika, nego kvadratnog zato što predstavlja produkt dvije linearne interpolacije. Za postupak bilinearne interpolacije potrebne su četiri točke, a provodi se pomoću linearnih interpolacija u dva smjera koordinatnog sustava. U ovom projektu koristi se pojednostavljeni prikaz formule za bilinearnu interpolaciju nad točkama.

Za prikaz pojednostavljene formule mogu se uzeti točke koordinata: (0,0), (0,1), (1,0) i (1,1) pa formula glasi:

$$f\ (s,t) = (1-s)(1-t)f(0,0) + \ s(1-t)f(1,0) + \ t(1-s)f(0,1) + stf(1,1) \quad (11)$$

gdje su s i t parametri za koje vrijedi:

$$s = x - \ \lfloor x \rfloor \quad \text{i} \quad t = y - \ \lfloor y \rfloor \quad (12)$$

2.4. Programska implementacija početne obrade slike

Početna obrada slike je implementirana u prototipu koji osim obrade služi i za detekciju Harrisovih kutova (implementacija detekcije je obrađena posebno u sljedećem poglavlju). Prototip je napisan u Pythonu (v2.7), skriptnom jeziku, i poslužio je kao svojevrsno upoznavanje s projektom i njegovom zahtjevnošću. Završna verzija, napisana u jeziku C++, sadrži funkcionalnost prototipa i algoritmi koji se koriste su skoro identični (njihovi pseudokodovi su dolje navedeni). Primjeri obrade slike koji su prethodno prikazani (Slika 1, 2 i 3) su rezultat prototipa (bez detekcije značajki). Pseudokovi algoritama obrade slike (izdvojeno je najbitnije):

- Pseudokod računanja gradijenta uz pomoć Sobelovog operatora:

```
Računanje gradijenta za X – os:
    Stvoriti potrebne kernele Sobelovog operatora;
    Izračunati prvu konvoluciju;
    Množiti vrijednosti piksela s prvim kernelom;
    Stvoriti praznu matricu gradijenata po X – osi;
    Izračunati drugu konvoluciju;
    Množiti vrijednosti piksela s drugim kernelom;
Ponoviti prethodno opisan postupak za Y – os;
```

- Pseudokod zaglađivanja rubova uz pomoć Gaussovog filtra:

```
Izračunati duljinu i stvoriti vektor te duljine;
Izračunati iznose Gaussove funkcije i središnji član;
Izračunati prvu konvoluciju vektora i originalne slike po X – osi;
Izračunati drugu konvoluciju vektora s prvom konvolucijom po
Y – osi ;
```

- Pseudokod interpolacije piksela:

```
Stvoriti matricu s realnim vrijednostima;
Izračunati duljinu polovice prozora;
Interpolirati piksel na realnim koordinatama funkcijom:
    Pomoću formule za bilinearnu interpolaciju
    izračunati potpikselnu interpolaciju jedne
    koordinate;
```

3. Harrisovi kutovi kao značajke slike

Postoje različite vrste značajki slike, a zajedničko im je što pružaju bitne informacije slike koje služe za određene operacije kojima se dolazi do rješenja. Značajke koje se koriste za praćenje u ovom projektu se nazivaju Harrisovi kutovi. Slika 4 prikazuje nađene značajke na jednom primjeru.

Slika 4 *– Nađeni Harrisovi kutovi se prikazuju crvenim rombovima u pregledniku i rezultatu (video datoteci koja uz originalni naslov sadrži '(pracenje)') završnog programa.*

3.1. Harrisovi kutovi

Postupak je predstavljen 1988. godine, ali još uvijek predstavlja jedan od najefikasnijih pristupa s fiksnim mjerilom za detekciju značajki.
Ideja algoritma je pronaći točke koje imaju maksimalnu različitost susjedstva u ovisnosti o zadanom pomaku. Autokorelacijska formula koja određuje različitost glasi:

$$Eq(d) = \Sigma x, y \epsilon W(q)[I(x + dx, y + dy) - I(x, y)]^2 \qquad (13)$$

$Eq(d)$ je vrijednost različitosti koja se traži. d je zadani pomak, a dx i dy su njegove komponente.

Traže se značajke u kojima Eq raste u svim smjerovima odnosno traže se okna s velikim promjenama inteziteta. Izraz I(x + dx, y + dy) može se aproksimirati Taylorovim redom gdje su Ix i Iy parcijalne derivacije.

Navedeni izraz prikazan u vektorskom obliku:

$$\Sigma qi \epsilon W(q)[I(qi + d) - I(qi)]^2 \qquad (14)$$

Nakon već spomenutog razvoja po Taylorovom redu dobiva se:

$$\Sigma qi(W)[I(qi) + \nabla I(qi) \cdot d - I(qi)]^2 \qquad (15)$$

Formula se također može prikazati u matričnom obliku:

$$M = \Sigma w(x, y) \begin{pmatrix} Ix^2 & IxIy \\ IxIy & Iy^2 \end{pmatrix} \qquad (16)$$

Tada jednadžba izgleda:

$$E(dx, dy) = (dx \quad dy) M \begin{pmatrix} dx \\ dy \end{pmatrix} \qquad (17)$$

Za svako detekcijsko okno računa se odziv i određuje sadrži li kut odziv veći od zadanog praga. Ako je odziv veći od zadanog praga okno se smatra kutom.

$$C = \frac{\lambda 1 \lambda 2}{\lambda 1 + \lambda 2} \qquad (18)$$

Odziv u formuli (18) računa se pomoću svojstvenih vrijednosti λ1 i λ2. To su svojstvene vrijednosti matrice M izračunate pomoću determinante i traga matrice M.
Slika 5 prikazuje nađene Harrisove kutove na jednom primjeru.

***Slika 5**– Primjer nađenih Harrisovih kutova. Crvenom bojom je označen uvećan dio iz neobrađene verzije (1), a plavom iz rezultata programa (2).*

3.2. Programska implementacija detektora Harrisovih kutova

Detekcija Harrisovih kutova je implementirana u prototipu, a tu sposobnost sadrži i završni program (uz korištenje sličnog algoritma prikazanog pseudokodom).

- Pseudokod algoritma detektora Harrisovih kutova:

```
Pomoću Sobelovog operatora izračunati gradijente (X i Y -osi);
Pomoću Gaussovog filtra zagladiti sliku i izračunati konvolucije;
Izračunati trag i determinantu matrice;
Pomoću svojstvenih vrijednosti izračunati odziv kuta (veća
vrijednost = veća vjerojatnost da je zapravo kut);
Uspoređivanje s okolnim susjedima u okolici prozora:
        Kut se ne sprema ukoliko susjedni kut ima veću
        vrijednost;
```

Slika 6 prikazuje izgled korisničkog sučelja prototipa i nađene značajke na primjeru.

Slika 6 *– Korisničko sučelje prototipa i njegov prikaz nađenih Harrisovih kutova za određenu veličinu prozora.*

Značajke se u slučaju prototipa prikazuju crvenim križićima. Interaktivno se određuje veličina prozora nakon čega prototip određuje koje kutove treba prikazati i zatim ih prikazuje (ako postoji spremljen rezultat za određenu sliku i veličinu prozora, prikazuje taj rezultat), a njihov broj se ispisuje pokraj veličine prozora.
Python, koji se koristio u izradi prototipa, je iznimno popularan programski jezik. Zbog jednostavnosti pisanja, intuitivnosti, preglednosti i bogate biblioteke (i velike zajednice koja nastoji što više proširiti tu biblioteku i općenito poboljšati mogućnost koje Python nudi) privlači ljude programiranju i upoznaje ih s osnovnim principima programiranja. Navedeno je samo dio velikih mogućnosti koje ovaj jezik nudi jer koriste ga i mnogo iskusniji programeri u zadaćama koje ne zahtijevaju veliku brzinu izvođenja. Python je skriptni jezik visokog nivoa i kao takav je, u usporedbi s popularnim jezicima niskog nivoa (C, Java, C++ itd.), spor u izvođenju operacija. Jednostavan primjer je izvođenje prototipa prikazano na slici 3.2 gdje je bilo potrebno oko 30 sekundi za nalaženje liste svih potencijalnih kutova (iako, uz veće optimiziranje se to vrijeme vjerojatno moglo malo smanjiti). U KLT pratitelju se koristi periodičko detektiranje Harrisovih kutova u nizu slika što znači da bi praćenje značajki zahtijevalo mnogo vremena. To je ujedno i glavni razlog zašto je završni program napisan u jeziku C++, programskom jeziku niske razine, koji omogućava praćenje značajki, ovisno o rezoluciji slike, u stvarnom vremenu ili razumnom vremenskom roku.

4. Algoritam KLT

Praćenje značajki između slika ima brojne primjene u području računalnog vida, a kako je većina tada poznatih algoritama bila spora, 1981. godine Bruce D. Lucas i Takeo Kanade kreiraju novi postupak koji se bazira na diferencijalnom praćenju optičkog toka, za koji pretpostavlja da je konstantan u okolici promatranog piksela te metodom najmanjeg kvadrata rješava jednadžbe optičkog toka, a namjena mu je poravnavanje predloška i ulazne slike što ostvaruje pronalaskom zajedničkih značajki na obje slike. Na temelju tog postupka, kasnije je u suradnji s Carlom Tomasijem razvijen postupak za praćenje značajki nazvan Kanade-Lucas-Tomasi pratitelj značajki (skraćeno KLT pratitelj). Jednostavna verzija algoritma KLT će učitati početnu sliku, na njoj pronaći značajke koje se prate te ih spremiti, zatim učitati slijedeću sliku, pomoću Lucas-Kanade metode iterativno pronaći na njoj te iste značajke sa prethodne slike, obustaviti traženje izgubljenih značajki i spremiti podatke o svim značajkama koje prati. Nakon što je obavljen algoritam za dvije slike, početna slika se zamjenjuje nasljednikom, te se kao druga slika učitava slijedeća te se takav postupak ponavlja do kraja video zapisa ili niza slika nad kojima se obavlja praćenje. U slučaju većeg niza slika, zbog konstantnog gubitka postojećih (npr. napuštanje kadra) te pojavljivanja novih značajki, detektiranje novih značajki će se uobičajeno pozivati nakon određenog broja slika te dodavati nove značajke u postupak praćenja. Prednost KLT algoritma nad ostalim algoritmima sličnog tipa je također i u tome što podržava praćenje podpikselnih pomaka, odnosno, pomak sa razlučivošću manjom od jednog piksela. Sve navedene jednadžbe vrijede i za realne brojeve pa je time moguće praćenje podpikselnih pomaka, međutim se pojavljuje problem prikazivanja takvih pomaka na ekranima, jer je njihova razlučivost pikselna, tako se samo pomaci računaju u podpikselnoj preciznosti što omogoćuje preciznije izračune i obradu dobivenih podataka, ali se ta preciznost gubi prikazom pomaka na ekranu.

Značajke (značajne informacije) se mogu određivati na različite načine, a u implementaciji ovog projekta se koriste Harrisovi kutovi nađeni Harrisovim detektorom. Postupci obrade slike i detekcije značajki se mogu pročitati u prethodnim poglavljima.

Slijedi algoritam KLT:

- ***Korak 1.*** Označiti prvu sliku simbolom I, drugu sliku simbolom J, a lokaciju značajke pronađenu na prvoj slici vektorom $\bar{u} = [u_x \quad u_y]^T$. Ključni dio samog algoritma je pronalazak značajke **u**, koju smo detektirali na prethodnoj slici i na slijedećoj slici. Taj pronalazak se vrši tako da se nalazi prozor na drugoj slici koji je dovoljno sličan prozoru na prvoj slici koji sadrži traženu značajku. Sličnost na slici se definira pronalaskom vektora pomaka

$$\bar{d} = [d_x \quad d_y]^T \qquad (19)$$

za koji će sljedeća funkcija biti minimalna.

$$\varepsilon(d_x, d_y) = \sum_{x=u_x-\omega_x}^{u_x+\omega_x} \sum_{y=u_y-\omega_y}^{u_y+\omega_y} (I(x,y) - J(x+d_x,\ y+\ d_y))^2 \quad (20)$$

U prikazanoj jednadžbi ω_x te ω_y predstavljaju polovine veličine prozora, odnosno prozor je velik točno $(2\omega_x + 1) \times (2\omega_y + 1)$ piksela.

- Postupak dobivanja navedenog vektora:
  - ***Korak 2.*** Izračunati parcijalne derivacije slike I po x i y osima:

$$I_x(x,y) = \frac{I(x+1,y) - I(x-1,y)}{2} \qquad (21)$$

$$I_y(x,y) = \frac{I(x,y+1) - I(x,y-1)}{2} \qquad (22)$$

  - ***Korak 3.*** Kreirati matricu prostornih gradijenata H:

$$H = \sum_{x=u_x-\omega_x}^{u_x+\omega_x} \sum_{y=u_y-\omega_y}^{u_y+\omega_y} \begin{bmatrix} I_x^2(x,y) & I_x(x,y)I_y(x,y) \\ I_x(x,y)I_y(x,y) & I_y^2(x,y) \end{bmatrix} \qquad (23)$$

  - ***Korak 4.*** Incijalizirati vektor pomaka te postaviti vrijednosti na 0:

$$\bar{d} = [0 \quad 0]^T \qquad (24)$$

- ***Korak 5.*** Pokrenuti iterativan postupak traženja pomaka, koji se izvodi najviše ograničen broj puta (maksimalan broj iteracija - K) ili dok iznos konvergencije pomaka ne bude manji od graničnog nakon čega staje izvođenje te se zaključuje da je značajka pronađena. Koraci koji se provode u iterativnom postupku označeni su brojevima od 6 do 8:

    - ***Korak 6.*** Izračunati razliku između početne značajke i pretpostavljene lokacije značajke na drugoj slici:

$$\delta I_k(x,y) = I(x,y) - J(x + d_x, y + d_y) \qquad (25)$$

    - ***Korak 7.*** Izračunati vektor pogreške:

$$\bar{b}_k = \sum_{x=u_x-\omega_x}^{u_x+\omega_x} \sum_{y=u_y-\omega_y}^{u_y+\omega_y} \begin{bmatrix} \delta I_k(x,y) I_x(x,y) \\ \delta I_k(x,y) I_y(x,y) \end{bmatrix} \qquad (26)$$

    - ***Korak 8.*** Dobiveni vektor pogreške se pomnoži s inverzom prostorne matrice kako bi se dobili iznosi konvergencije pomaka. Iznos konvergencije se dodaje na dosadašnji pomak:

$$\bar{\eta}_k = H^{-1} \bar{b}_k \qquad (27)$$
$$\bar{d}_k = d_{k-1} + \bar{\eta}_k \qquad (28)$$

- Ukoliko je zadovoljen barem jedan od slijedećih uvjeta, iteracija iz petog koraka se prekida:

    - ***Uvjet za prekid iteracije 1.*** Ukoliko je iznos konvergencije pomaka manji od graničnog, može se zaključiti da je izraz iskonvegirao te je pronađena značajka na slici J koja je određena sljedećim vektorom:

$$v = u + d \qquad (29)$$

    - ***Uvjet za prekid iteracije 2.*** Ukoliko je brojač iteracija dosegnuo maksimalan broj iteracija K, a postupak nije iskonvergirao, iteracija se zaustavlja. Vektor v može, ali i ne mora pokazivati na značajku te takvu analizu smatramo neuspješnom, a značajku izgubljenom.

5. Programska implementacija algoritma KLT

Sposobnost prototipa (detekcija Harrisovih kutova) je implementirana u završnom programu koji je napisan u jeziku C++, programskom jeziku opće namjene. Osim navedenog, završni program ima sposobnost praćenja značajki, a to postiže, algoritmom KLT koji je naveden u prethodnom poglavlju. Postoje dva osnovna načina rada završnog programa:

- Praćenje značajki između dvije slike u kojem se razlikuju također dva načina rada:
  - Praćenje ručno odabrane značajke
  - Praćenje detektiranih značajki (Harrisovih kutova)
- Praćenje značajki u video datoteci

Navedeni načini rada imaju vlastita jednostavna korisnička sučelja i opisani su u sljedećim podpoglavljima. Do određenog načina rada se dolazi izbornicima završnog programa što je detaljnije objašnjeno u osmom poglavlju 'Upute za korištenje'.

5.1. Praćenje značajki između dvije slike

Prije implementiranja algoritma KLT u svrhu praćenja značajki u video datoteci potrebno je bilo testirati navedeni algoritam u slučaju dvije slike u kojima se može lakše pratiti rezultat izvedbe. Kao testni primjer su se koristile dvije jednostavne slike koje imaju istaknuti crni trokut i pravokutnik na bijeloj podlozi. Ti geometrijski likovi su idealni za promatranje praćenja Harrisovih kutova. Razlike u položaju odnosno pomak između slika iznosi nekoliko piksela.

Praćenje značajki između dvije slike se može odvijati na dva načina. Jedan od njih je ručno označavanje značajke koju želimo pratiti. U tom načinu se ne koristi detektor Harrisovih kutova već se prati ručno označena značajka.

Slika 7 prikazuje korisničko sučelje završnog programa u kojem se prati ručno odabrana značajka.

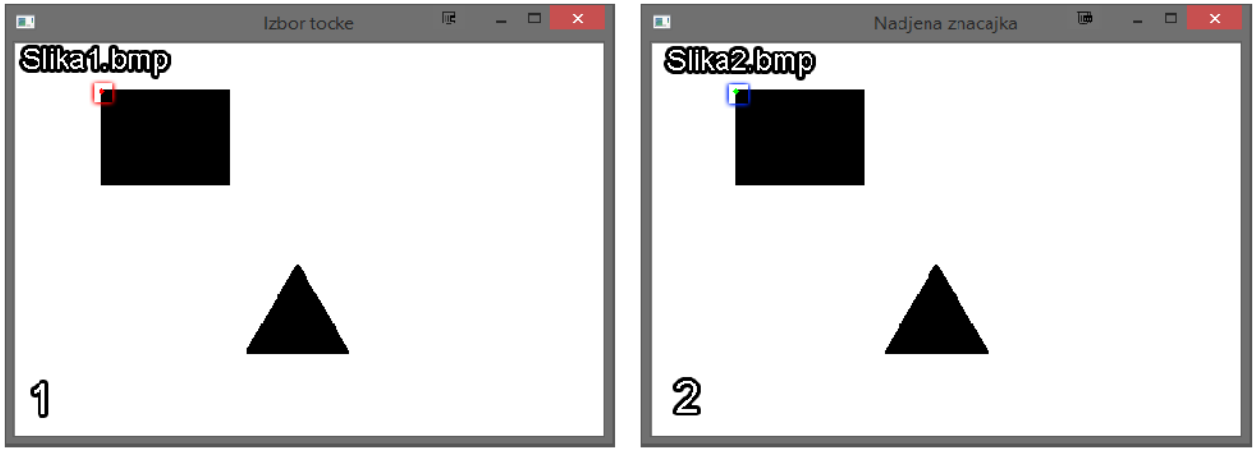

Slika 7 *– U prozoru 'Izbor tocke' (1) se klikom lijevog miša odabere značajka i zatim se u prozoru 'Nadjena znacajka' (2) prikazuje značajka nađena algoritmom KLT. Odabrana značajka je označena crvenim, a nađena značajka zelenim rombom (uvećano zbog preglednosti).*

Drugi način je praćenje automatski nađenih značajki. Umjesto praćenja ručno označene značajke, u ovom slučaju se prate nađeni Harrisovi kutovi na prvoj slici.

Slika 8 prikazuje korisničko sučelje završnog programa u kojem se prati automatski nađene značajke.

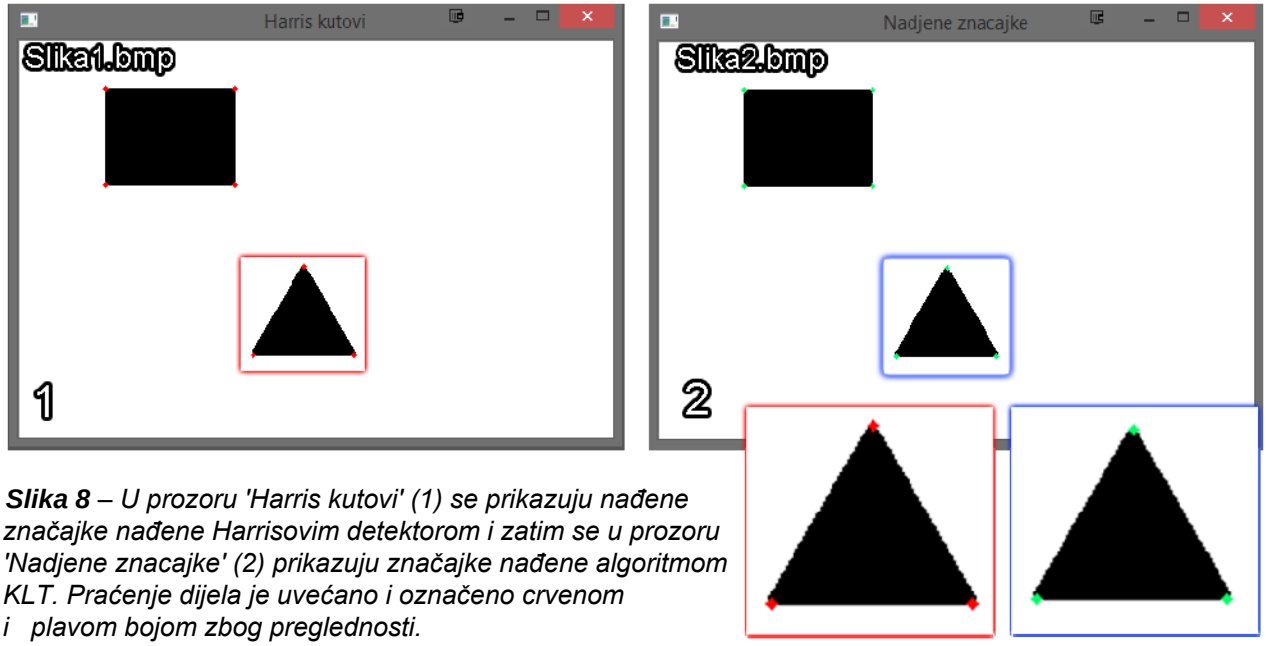

Slika 8 *– U prozoru 'Harris kutovi' (1) se prikazuju nađene značajke nađene Harrisovim detektorom i zatim se u prozoru 'Nadjene znacajke' (2) prikazuju značajke nađene algoritmom KLT. Praćenje dijela je uvećano i označeno crvenom i plavom bojom zbog preglednosti.*

5.2. Praćenje značajki u video datoteci

Video datoteku možemo promatrati kao niz slika (eng. *frames*). Zbog prirode ljudskog vida ljudski mozak može percipirati 10 do 12 individualnih slika u jednoj sekundi no povećanjem tog broja (FPS-a)[3] se dobiva osjećaj pokreta. Daljnjim povećanjem FPS-a se povećava fluidnost pokreta što uzrokuje subjektivno ugodniji prikaz. Dogovorno su određeni standardi, koji uzimaju u obzir navedeno uz cijenu izrade i objave video snimki, i iznose 24 (u današnje vrijeme najraširenija), 25 i 30 slika u sekundi. Zbog razvoja i dostupnosti određenih tehnologija taj će se broj u bližoj budućnosti sigurno povećati.

Princip praćenja značajki uz pomoć KLT algoritma je isti kao za praćenje između dvije slike. Jedina razlika je u tome što se nakon svakih 20 slika koristi detektor Harrisovih kutova tj. u tom slučaju se umjesto praćenja koristi detekcija značajki. Razlog tome je što video snimka može imati naglu promjenu slike (primjer je novi kadar u filmu ili brzi pokret prikazanog lika). Bez periodične detekcije značajke se u tom slučaju mogu izgubiti i njihovo praćenje će biti obustavljeno jer jednom odbačene značajke se više ne uzimaju u obzir.

Korisničko sučelje završnog programa u načinu rada praćenja značajki u video datoteci sadrži tri postavke koje se mogu mijenjati usred praćenja:

- Broj značajki pod postavkom 'Znacajke' u kojoj se može odrediti koliko će se detektiranih kutova odabrati za praćenje. Ovom postavkom se može demonstrirati što bi se dogodilo kad ne bi bilo periodične detekcije značajki (to se može napraviti tako da se usred praćenja broj značajki smanji na nula). Početna vrijednost iznosi 15.
- Prag detekcije Harrisovih kutova pod postavkom 'Harris'. Početna vrijednost iznosi 1000. Detektirane značajke su označene ljubičastim rombovima.
- Prikaz praćenja u kojem program čeka korisnikov upis za prikaz sljedeće slike video datoteke. Početno je ta opcija isključena.

Rezultat završnog programa u ovom načinu je video datoteka istog imena kao ulazna datoteka uz dodatak ' (pracenje)' koja sadrži detektirane i praćene značajke. U slučaju prekida završnog programa usred praćenja, izlazna video datoteka ima trajanje do trenutka prekida.

Slika 9 prikazuje korisničko sučelje završnog programa u načinu rada praćenja značajki u video datoteci.

[3] **FPS** je akronim za broj slika u sekundi (eng. ***Frames per second***) i koristi se u računalnoj grafici i filmu. Odličan primjer koliko FPS utječe na prikaz slike se može ovdje interaktivno pogledati: http://goo.gl/mTBDu

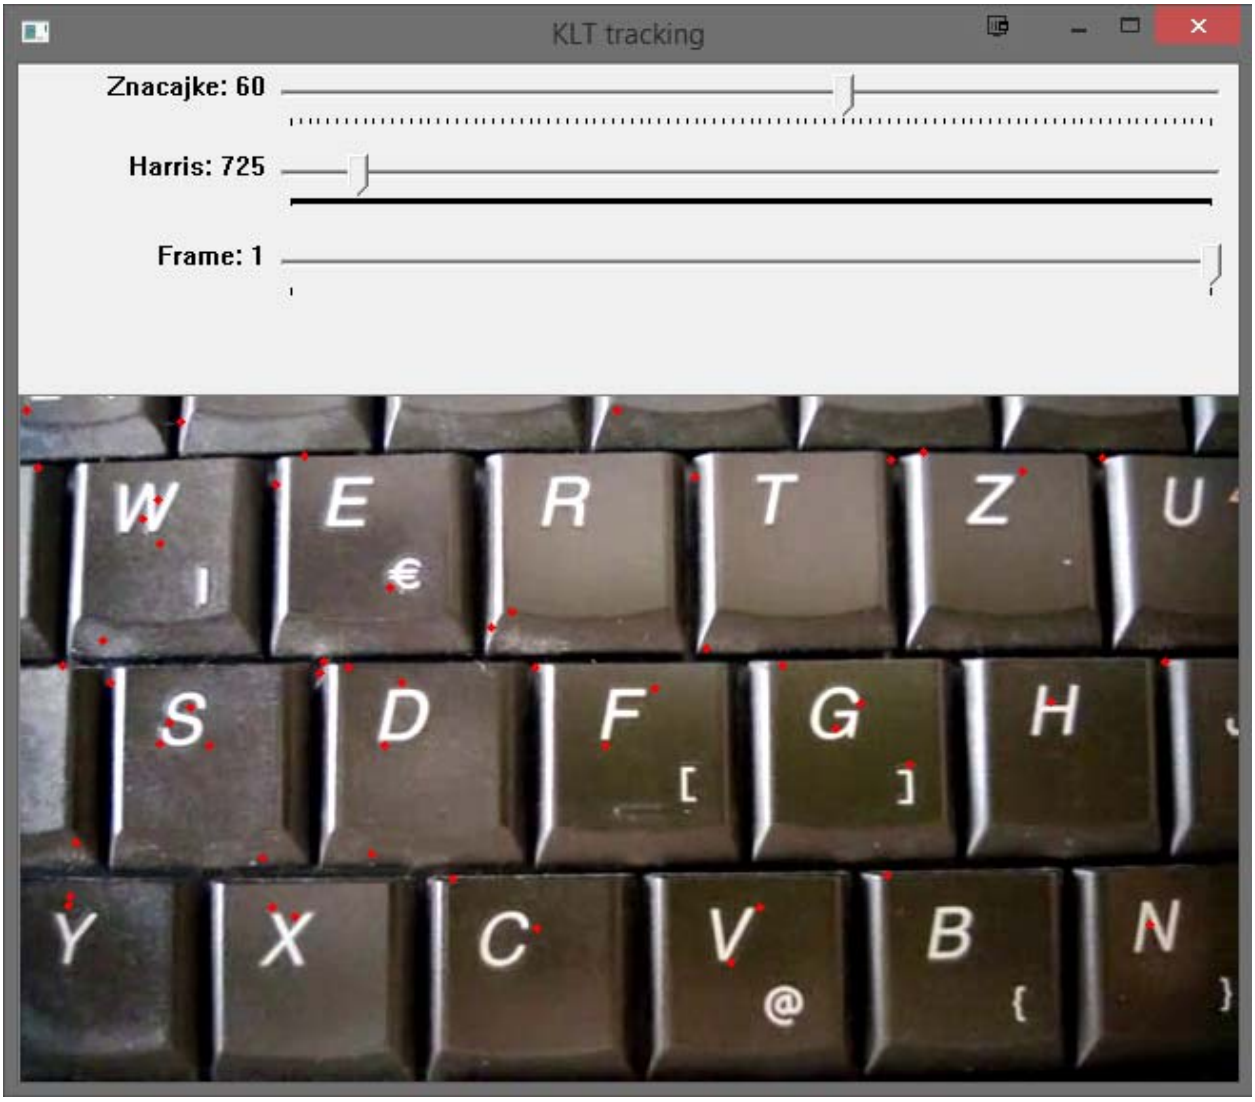

Slika 9 *– Crvenim rombovima su označene praćene značajke. Na vrhu prozora 'KLT tracking' se mogu vidjeti postavke programa koje se mogu interaktivno mijenjati.*

6. Eksperimentalni rezultati i problemi

Zadaća ovog projekta je bila pronaći i opisati rješenje problemskog zadatka pod imenom 'Elementarni postupak diferencijalnog praćenja'. Rješenje je nađeno u algoritmu KLT. Uz implementaciju navedenog algoritma potrebno je bilo implementirati i početnu obradu slike i detekciju značajki. Posljednje navedeno je prvotno izvedeno u obliku prototipa. Nakon uspješne izrade prototipa izrađuje se završni program koji osim sposobnosti prototipa sadrži i sposobnost praćenja značajki odnosno rješenje u punom obliku. Analizom rezultata završnog programa može se zaključiti da je programska implementacija algoritma KLT uspješno napravljena no svakako postoji prostor za doradu i optimizaciju.

Osim poboljšanja izvedbe postoje i određeni problemi. To nisu nužno greške, primjer je vrijeme izvođenja prototipa i završnog programa koje se može vjerojatno malo ubrzati daljnjom optimizacijom no najprije je limitirano programskom i hardverskom platformom. Razlika između izvođenja u programskim jezicima Python i C++ je objašnjena u poglavlju 3.2 Programska implementacija detektora Harrisovih kutova. Primjer hardverskog ograničenja je izvođenje na računalu sa starijim, ali svejedno modernim, dvojezgrenim procesorom Intel Core 2 Duo E8200 (@2.66 GHz) s veličinom priručne memorije (eng *cache*) od 6 MB. Na njemu se izvođenje praćenja značajki na videu, u današnje vrijeme, relativno niske rezolucije od 640x360 piksela (rezolucija primjer video datoteke video.avi) prikazuje u skoro 'stvarnom vremenu' (FPS iznosi oko 25). Za veću rezoluciju od 1280x720 piksela (rezolucija primjer video datoteke spect.avi) to više nije slučaj (FPS iznosi oko 5). Treba napomenuti da je glavni uzrok ovog problema periodična detekcija značajki (Harrisovih kutova) koja zahtijeva mnogo računanja. Rješenje ovog problema je u izradi video datoteke koja se može pokrenuti neovisno o završnom programu i izvodi se kao ulazna video datoteka i sadrži nacrtane značajke. Time je omogućen pregled završnog rezultata u 'stvarnom vremenu' neovisno o hardverskoj platformi.

Standardni algoritam KLT (algoritam koji se koristio u ovom projektu) može pratiti značajke koje imaju mali pomak. Za veći pomak potrebno je implementirati tzv. KLT piramidu. Bez upuštanja u detaljniji opis može se ukratko napisati da KLT piramida funkcionira tako što se napravi nekoliko kopija trenutno gledane slike i svakoj kopiji je rezolucija dvostruka manja od prethodne. Izvodi se praćenje između najmanje kopije i slijedeće slike u video datoteci. Pomak značajke se množi dvostruko i zatim se postupak ponavlja za dvostruko veću kopiju, sve dok se ne dođe do originalne slike.

Slika 10 pokazuje primjer rezultata završnog programa u kojem se nađene značajke brzo izgube zbog relativno velikog pomaka.

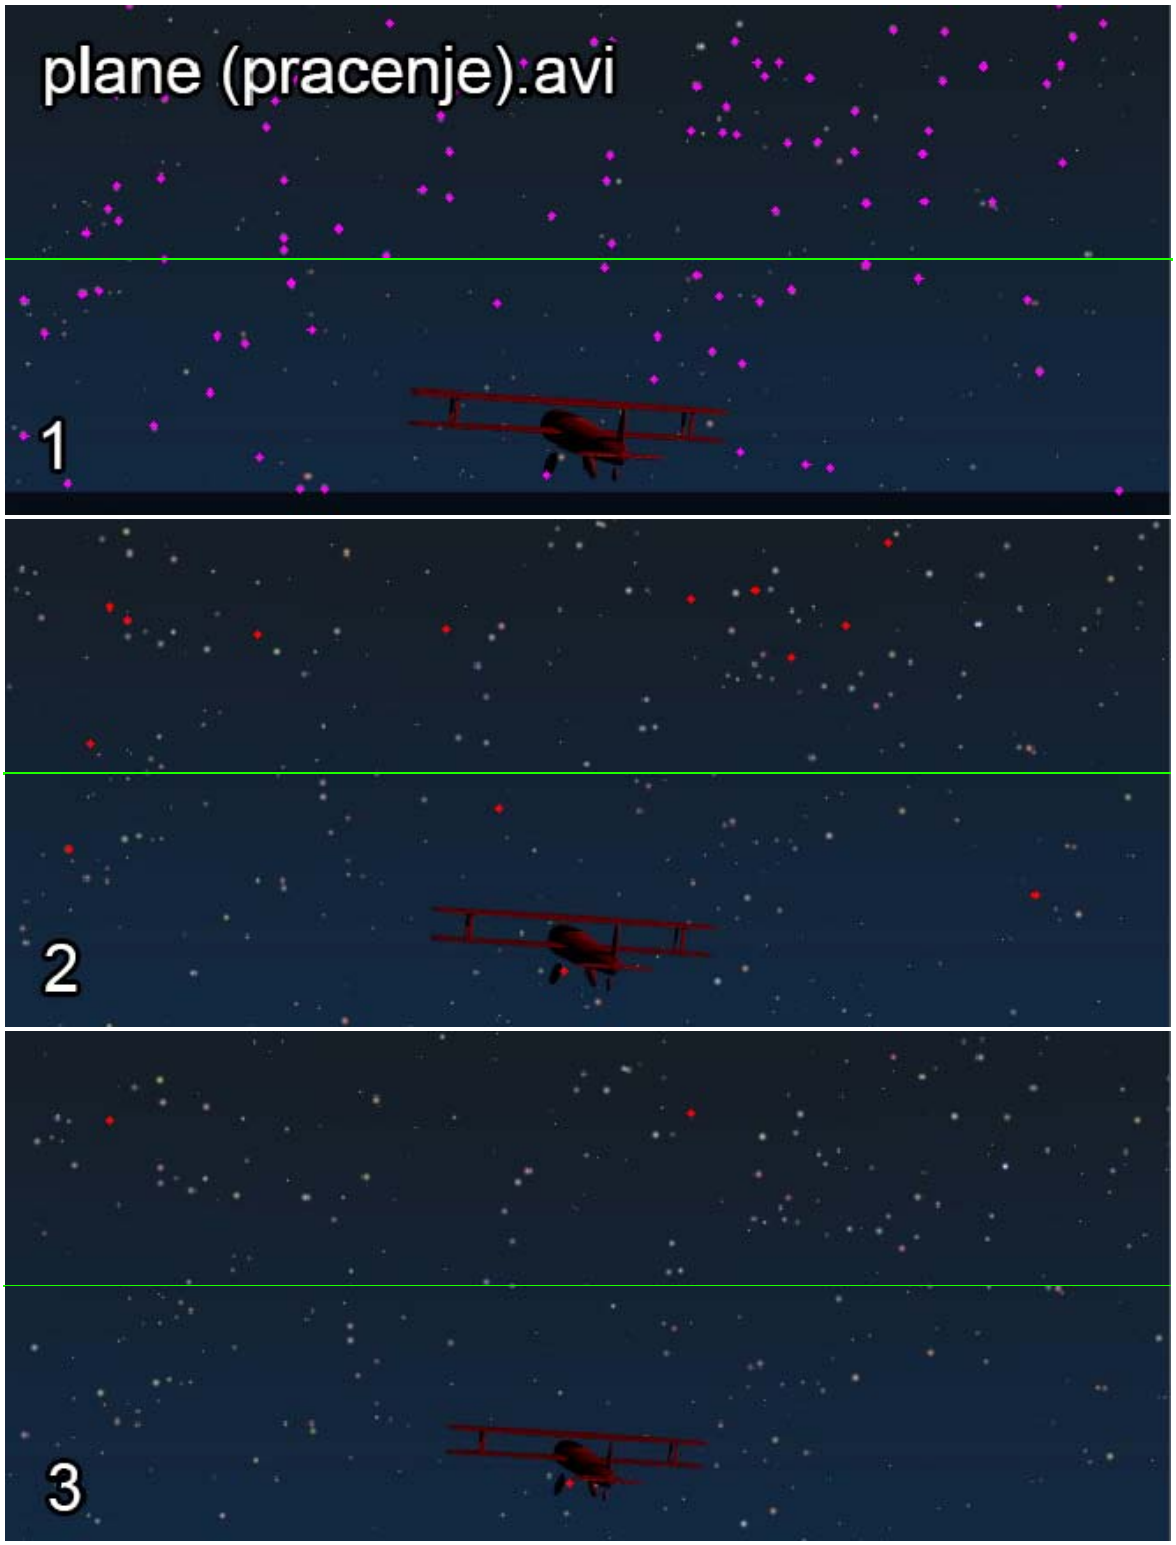

Slika 10 *– Prikazani su dijelovi uzastopnih slika iz jednog primjera. Zelenom bojom je označena polovica slika zbog preglednijeg praćenja pomaka. Mogu se vidjeti detektirane značajke označene ljubičastim rombovima (1) koje se ubrzo zbog većeg pomaka gube u sljedećim slikama (2) (3)*

Još jedan problem sa praćenjem javlja se ukoliko se na slici nalazi neka ravna linija, točka koju pratimo nalazi na toj liniji i pomak je specifičan. Slikovit primjer je šahovska ploča i točka praćenja koja se nalazi na sredini linije koja spaja crno i bijelo polje. Linija je horizontalna tj. ona "dolje" ili "gore". Ukoliko se javi pomak koji je također horizontalan, javi se problem. KLT pratitelj će tijekom prvog koraka algoritma staviti koordinatu za iduću sličicu na zadnju poznatu sa prošle sličice. Cijela okolina oko točke koja se prati praktički je ista kao i sama točka. Zbog toga će KLT pratitelj zaključiti da je odmah "pogodio" i ostaviti točku na toj koordinati. Krajnji rezultat zbog toga izgleda kao da točka stoji, a slika se miče iako se zapravo i ta točka miče skupa sa slikom. To se javlja sve dok ne dođe do nekog dijela slike koji je različit od ovog. Također se ovaj problem javlja i za druge orijentacije linije, ali onda i pomaci moraju biti u skladu s tom linijom.

U rezultatu završnog programa se može primijetiti povremeno 'titranje' nekih značajki u horizontalnom i vertikalnom smjeru. To se događa zbog zaokruživanja koordinata značajki na cijeli broj (zaokruživanjem se gubi podpikselna preciznost) i dio je algoritma KLT.

Detekcija značajki se obavlja svakih 20 slika u video datoteci. Time se osigurava periodično 'obnavljanje' položaja značajki što je korisno u video datotekama u kojima se slike naglo mijenjaju (primjer je promjena kadra u filmu). Uzimajući u obzir da je današnji najčešći standard oko 24 FPS-a u video datotekama, može se zaključiti da se detekcija obavlja periodično manje od jedne sekunde, što je relativno brzo. To nekad nije dovoljno što se može vidjeti u rezultatu za primjer video datoteku 'battle.avi'. To je isječak iz akcijskog filma u kojem se vrlo brzo izmjenjuju kadrovi i može se primijetiti detekcija značajki koja 'kasni' za izmjenom kadra. Daljnje smanjenje tog broja nije preporučljivo jer detekcija značajki uzima veći dio vremena izvedbe.

7. Zaključak

Ovim projektom se može dobiti iskustvo malog dijela područja računalnog vida. Pritom se ne misli samo na krajnji rezultat već i sve ono što je bilo potrebno napraviti da bi se došlo do toga. Trebalo je, prije svega, razumjeti na koji način računalo zapisuje sliku. Kako se određuje što jest, a što nije nekorisna informacija (šum). Što je to točno značajna informacija slike (značajka) i čemu ona služi. Trebalo je odrediti koja će se vrsta značajki koristiti u ovom projektu. Kojom će se metodom slika obrađivati za što brže nalaženje tih značajki. Zatim je bilo potrebno naći način kojim se smanjuje šum, ali i ne ugrožava korisna informacija slike. Nakon svega trebalo je pronaći način na koji će se pronađene značajke pratiti u nizu slika. Koji su rizici praćenja. Kako unaprijediti krajnji rezultat.
To je sve dio područja računalnog vida. Za potpuno razumijevanje je potrebno dobro predznanje dijela više matematike.

Osnovno diferencijalno praćenje je ovim projektom ostvareno no postoji prostor za nadogradnju kojom bi projekt postao korisniji u nekoj primjeni.
Moguće je dodati određivanje puta neke značajke kojim se ona pomicala. Koliko je bilo trajanje pronađene i praćene značajke. Koliko je značajki potrebno za određivanje pojedinog objekta. Pomoću svega navedenog moguće je odrediti koliko se određeni objekt nalazio u kadru. Jednostavan primjer toga bi bilo praćenje i bilježenje odlaska autobusa na autobusnim stanicama. U istu svrhu bi se mogla pratiti prometovanje određenom ulicom. To je samo jedan od mnogih primjera u kojem bi se nadogradnjom povećala korisnost ovog projekta.

8. Upute za korištenje programske implementacije

Kako je programska implementacija napravljena u dva dijela posebno će se za svaku napisati što je potrebno za pokretanje i kompiliranje kako bi programi uspješno izvodili ono što je opisano u ovom projektu. U svakom dijelu će biti ukratko napisana struktura izbornika odnosno kako se do njih dolazi. Uz dokumentaciju su priloženi primjeri ulaznih video datoteka: 'battle.avi', 'plane.avi', 'spect.avi', 'video.avi' i 'video2.avi' (zadnja dvije navedene su napravljene u svrhu ovog projekta, a ostale preuzete s interneta). Video datoteke mogu biti ulaz isključivo završnog programa i moraju biti u AVI formatu. Uzrok tome je korištenje biblioteke OpenCV (2.4.6) koja ne podržava druge formate. Također su priložene slikovne datoteke: 'slika1.bmp', 'slika2.bmp' i 'slika3.bmp' (napravljene u svrhu ovog projekta). Slikovne datoteke mogu biti ulazi obje verzije i mogu biti u popularnim formatima (BMP, JPG, PNG). Izlazne datoteke odnosno rezultati ovise o korištenoj verziji programa.

8.1. Prototip: Upute za korištenje

Prototip je napisan u Pythonu, a za njegovo izvođenje i kompiliranje je potrebno Python razvojno okruženje sa sljedećim dodacima:

1. Numpy (za korištenje matrica)
2. OpenCV (za ulazi i izlaz slikovnih datoteka)
3. PIL (za korisničko sučelje)

Python okruženje, 1. i 2. dodatak uz objašnjenje instalacije je moguće ovdje dobaviti: http://goo.gl/6m0nQx
Modul PIL je moguće dobaviti ovdje: http://goo.gl/DPHxOY (potrebno je izabrati najnoviju verziju za Python v2.7).

Nakon obavljene instalacije svega potrebnog ulaznu sliku je potrebno staviti u folder 'Input'. Pokretanjem prototipa se pojavljuje izbornik u kojem je potrebno odabrati slikovnu datoteku. Nakon toga se pokreće izvedba prototipa (dvoklikom na ikonu programa ili u Python Shellu) i ispisuju se koraci. Nakon završetka izvedbe pojavljuje se prozor 'Harrisovi kutovi' u kojem je moguće mijenjati veličinu prozora (upiše se broj i pritisne tipka Enter) nakon čega se mijenja prikaz i ispisuje broj kutova. Preporučljivo je izabrati manji broj veličine. Osim što se izlazni rezultat prikazuje u korisničkom sučelju prototipa, on se zapisuje i u folderu Output/harris_temp uz sliku koja sadrži samo značajke u obliku točki.

8.2. Završni program: Upute za korištenje

Završni program je napisan u programskom jeziku C++, a za njegovo izvođenje nije potrebna instalacija dodataka, potrebni su jedino datoteke koje su priložene uz kompiliranu verziju. Za kompiliranje završnog programa je potrebno C++ razvojno okruženje (primjer su Visual Studio 20XX za Windows OS i Eclipse za Linux OS) uz korištenje dodatka OpenCV. Za potpuno jamčenje izvedbe projekta savjetuje se koristiti Visual Studio 2010 i OpenCV 2.4.6. jer je programski kod napisan i uspješno testiran u tim verzijama. Objašnjenje instalacije OpenCV biblioteke se može ovdje dobaviti: http://goo.gl/WQOLkk

Preporučljivo je uključiti optimizacije kompilatora vezane za povećanje brzine izvođenja izvršnog programskog koda te kompilirati navedeni kod u 'release' verziji. Određivanje optimizacijskih postavki se mogu vidjeti na slici 11.

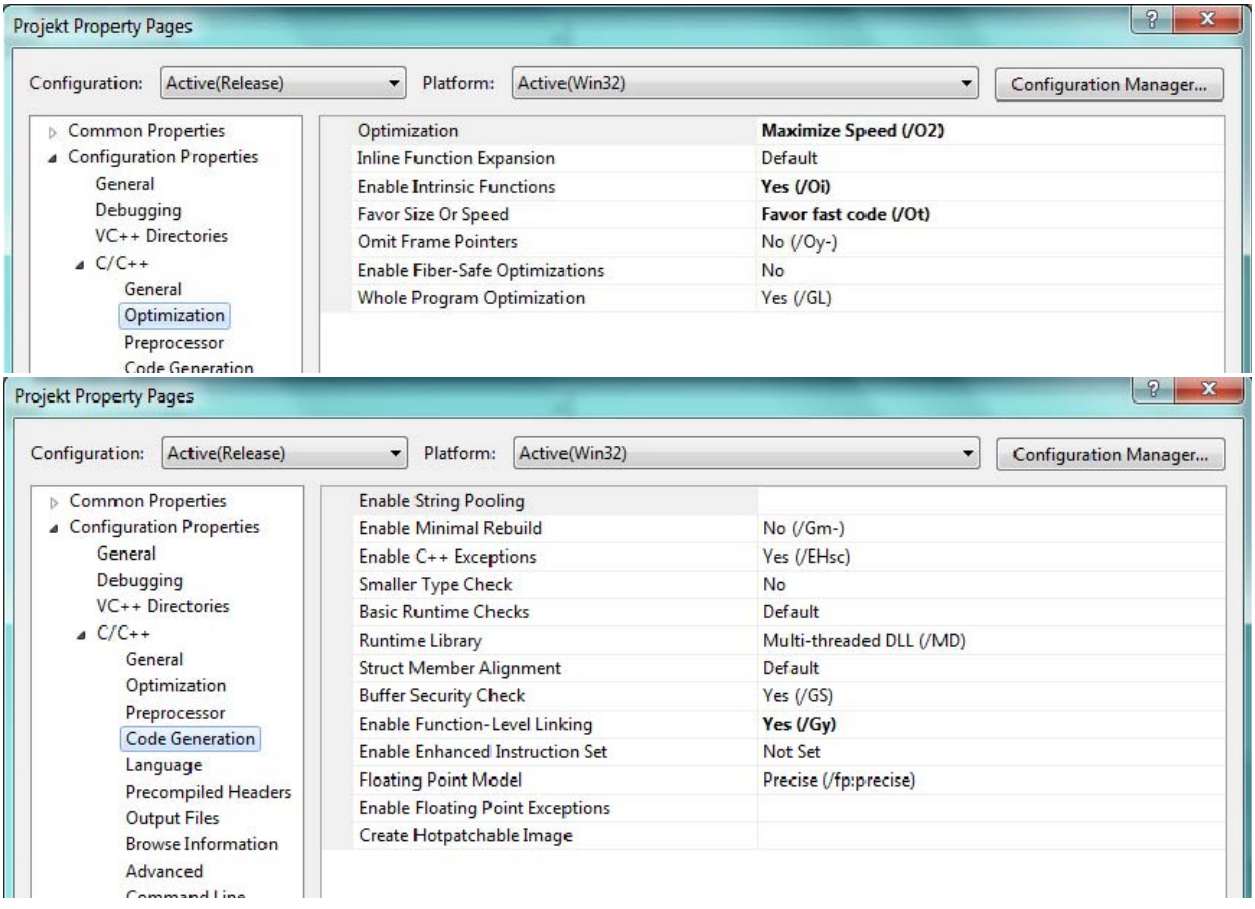

Slika 11 *– Prikazane su postavke koje treba namjestiti kako bi se ubrzalo izvršavanje programskog koda.*

Za detaljniji prikaz koliko što troši resursa moguće je pogledati dvije priložene slikovne datoteke koje u naslovu imaju dio 'Profil_izvođenja'. U oba slučajeva je postavljen prag detekcije od 4000, a razlikuju se u broju značajki (u jednoj je 25, a u drugoj 50 značajki).

Pokretanjem završnog programa pojavljuje se glavni izbornik sa sljedećim opcijama:

- Rad sa slikama
- Rad sa videom
- Kraj rada

Pokraj svake opcije je naveden broj s kojim se odabire određena opcija.
U slučaju rada sa slikovnim datotekama pojavljuje se nova lista opcija 'Odaberite format' u kojem se traži format ulazne slikovne datoteke. Odabirom formata se pojavljuje unos za ime prve slike. Potrebno je upisati ime prve slikovne datoteke, pritisnuti tipku Enter i zatim napraviti isto za drugu slikovnu datoteku.
Pojavljuju se dvije opcije:

- Pracenje rucno odabrane znacajke
- Pracenje nadenih Harrisovih kutova

Odabirom opcije se pojavljuju određena korisnička sučelja. U slučaju prve opcije za praćenje značajke je potrebno ručno odabrati značajku na prozoru 'Izbor znacajke' pritiskom na lijevu tipku miša. Zatim se pritiskom tipke Space praćena značajka pojavljuje u prozoru 'Pracena znacajka'. Za povratak u glavni izbornik je potrebno pritisnuti tipku Space.

U slučaju druge opcije se pojavljuje prozor 'Harrisovi kutovi' na kojem su prikazane nađene značajke. Pritiskom tipke Space praćene značajke se pojavljuju u prozoru 'Pracene znacajke'. Za povratak u glavni izbornik je potrebno pritisnuti tipku Space.

U slučaju rada sa video datotekama pojavljuje se unos za ime video datoteke. Potrebno je upisati ime video datoteke i pritisnuti tipku Enter.
Pojavljuje se prozor 'KLT tracking' s postavkama i prostorom za slikovni prikaz. Izvedba završnog programa se pokreće pritiskom na tipku Space. Postavke se mogu interaktivno mijenjati. Ako se želi samo slikovni prikaz bez postavki potrebno je pritisnuti lijevom tipkom miša na X na vrhu prozora. Za povratak u glavni izbornik je potrebno pritisnuti tipku Escape. Izlaz završnog programa je video datoteka koja u sebi uz ime ulazne datoteke sadrži dio ' (pracenje)' i sadrži detektirane i praćene značajke.

9. Literatura

[1] Lucas-Kanade 20 Years On: A Unifying Framework, Baker and Matthews, veljača 2003.

[2] Computer Vision: Algorithms and Applications, Szeliski, rujan 2010.

[3] An Iterative Image Registration Technique with an Application to Stereo Vision, International Joint Conference on Artificial Intelligence, stranice 674-679, Bruce D. Lucas and Takeo Kanade, kolovoz 1981.

[4] http://docs.opencv.org/doc/tutorials/tutorials.html

[5] http://en.wikipedia.org/wiki/Sobel_operator, prosinac 2013.

[6] http://en.wikipedia.org/wiki/Gaussian_filter, rujan 2013.

[7] http://en.wikipedia.org/wiki/Corner_detection, studeni 2013.

[8] http://en.wikipedia.org/wiki/Interpolation, prosinac 2013.